# LAPORAN PRAKTIKUM 2

## Batch Data Ingestion & Processing with Spark

Untuk memenuhi tugas mata kuliah Teknologi Big Data

Dosen Pengampu: Bapak Muhayat, S.Ag., M.IT.


Oleh:

Siti Magfiratun Warahmah

Nim: 230104040059


**PROGRAM STUDI TEKNOLOGI INFORMASI**

**FAKULTAS DAKWAH DAN ILMU KOMUNIKASI**

**UNIVERSITAS ISLAM NEGERI ANTASARI BANJARMASIN**

**TAHUN 2026**

**Screenshot Spark berhasil berjalan "PIPELINE COMPLETED SUCCESSFULLY"**

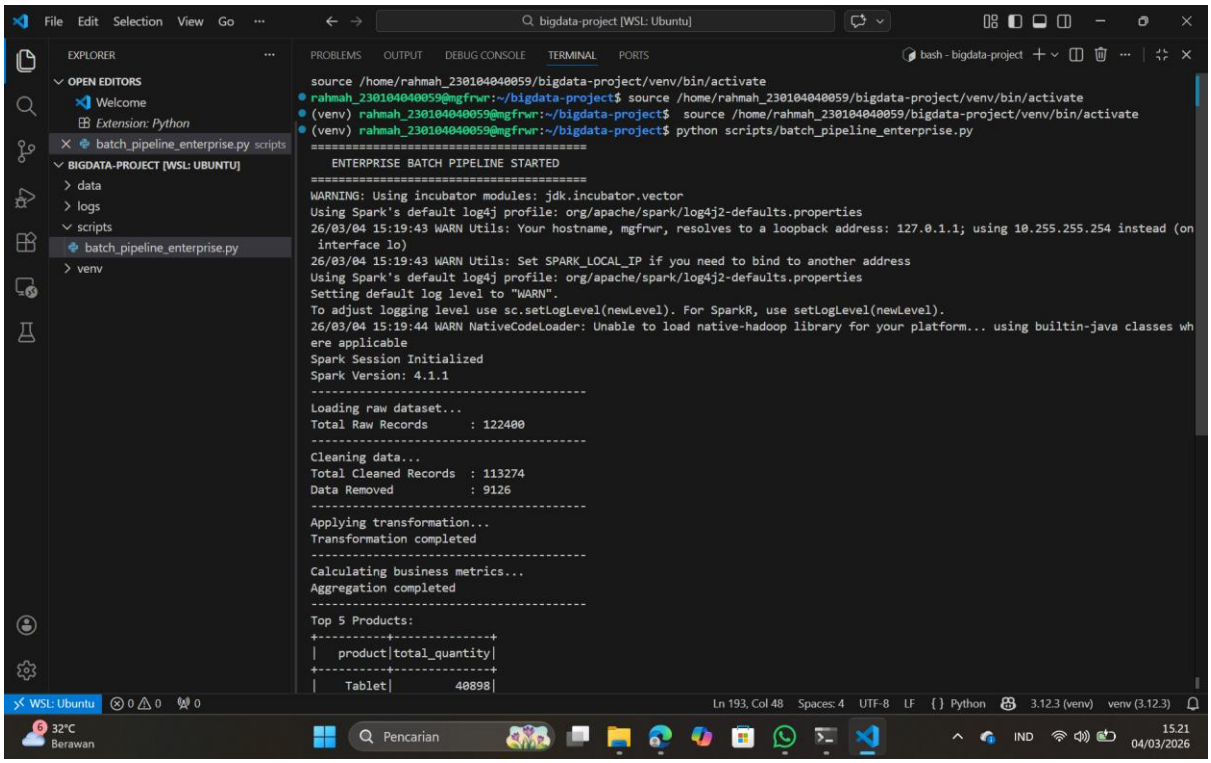


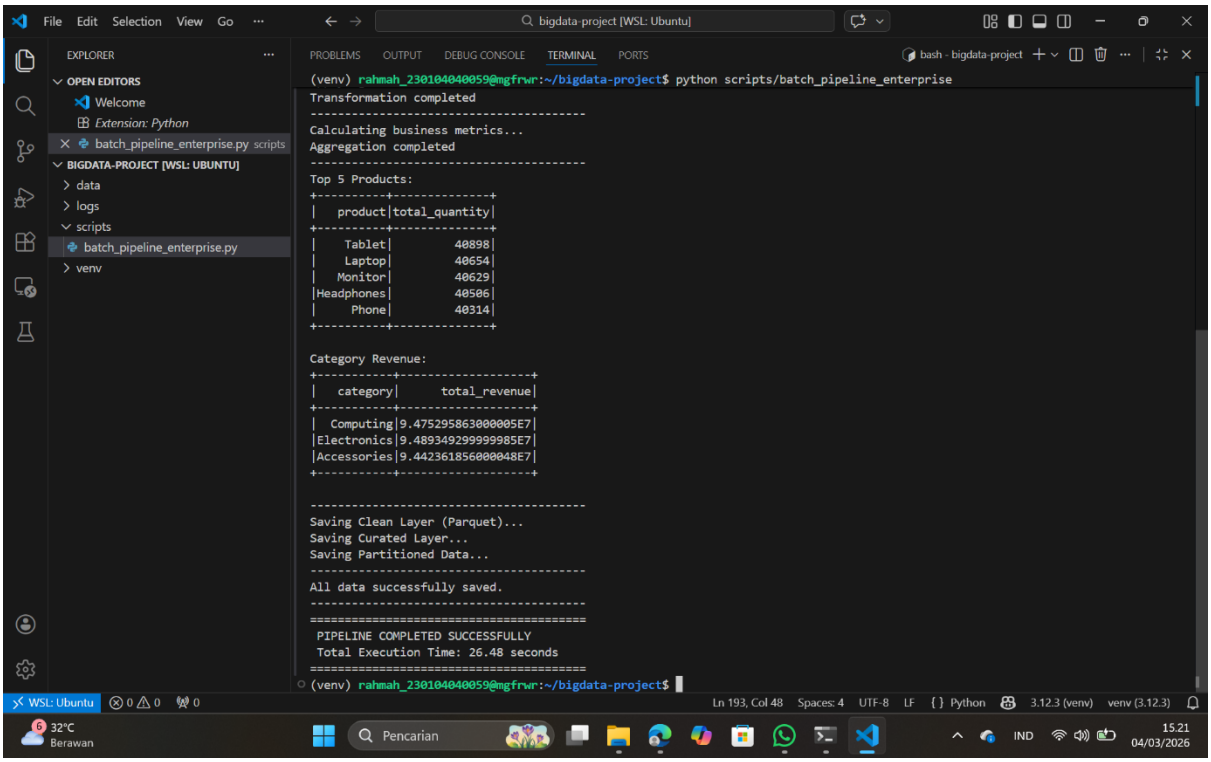


**Struktur Folder Output Hasil Pipeline**

Setelah proses batch pipeline selesai dijalankan, sistem menghasilkan beberapa folder output yang berisi data hasil pemrosesan. Struktur folder ini menunjukkan pembagian data berdasarkan layer pemrosesan, yaitu clean layer dan curated layer.

Folder `data/clean/parquet/` berisi dataset yang telah dibersihkan dan disimpan dalam Format Parquet.

Folder `data/clean/partitioned_by_category/` berisi dataset yang telah dipartisi berdasarkan kategori produk.

Sedangkan pada folder curated terdapat hasil agregasi data yaitu:

- `data/curated/top_products/`
- `data/curated/category_revenue/`

Struktur folder ini menunjukkan bahwa pipeline berhasil menghasilkan output data sesuai dengan desain arsitektur data pipeline yang dibuat.

```
● (venv) rahmah_230104040059@mgfrwr:~/bigdata-project$ tree -L 2 data
  data
  ├── clean
  │   ├── parquet
  │   └── partitioned_by_category
  ├── curated
  │   ├── avg_transaction
  │   ├── category_revenue
  │   └── top_products
  └── raw
      ├── ecommerce_raw.csv
      └── ecommerce_raw.csv:Zone.Identifier
```

**Analisis Hasil Praktikum Batch Data Pipeline dengan Apache Spark**

**1. Penjelasan Singkat Batch Processing**

Batch processing merupakan metode pemrosesan data dalam jumlah besar yang dilakukan secara berkala dalam satu kelompok proses (batch), bukan secara langsung atau real-time. Dalam pendekatan ini, data dikumpulkan terlebih dahulu selama periode tertentu, kemudian diproses sekaligus menggunakan sistem komputasi yang mampu menangani volume data besar secara efisien.

Pada praktikum ini, batch processing diimplementasikan menggunakan **Apache Spark versi 4.1.1** melalui script Python bernama **`batch_pipeline_enterprise.py`**. Pipeline yang dijalankan melakukan beberapa tahapan pemrosesan data transaksi e-commerce, yaitu mulai dari membaca dataset mentah, membersihkan data, melakukan transformasi, menghitung metrik bisnis, hingga menyimpan hasil pemrosesan ke dalam beberapa layer penyimpanan data.

Dataset awal yang diproses merupakan file **`ecommerce_raw.csv`** dengan total **122.400 baris data**. Setelah melalui proses pembersihan data (data cleaning), jumlah data yang tersisa menjadi **113.274 baris**, sehingga terdapat **9.126 baris data yang dihapus** karena tidak memenuhi kriteria kualitas data.

Setelah proses pembersihan selesai, pipeline melanjutkan tahap transformasi dan agregasi untuk menghasilkan informasi bisnis seperti **produk paling laris** dan **total pendapatan berdasarkan kategori produk**. Seluruh proses pipeline berhasil dijalankan tanpa error dan selesai dalam waktu sekitar **26,48 detik**.

**2. Mengapa Format Parquet Lebih Efisien**

Dalam praktikum ini, data hasil pembersihan disimpan dalam format **Parquet** pada folder `data/clean/parquet/`. Format Parquet dipilih karena memiliki beberapa keunggulan dibandingkan format teks biasa seperti CSV.

Pertama, **Parquet menggunakan penyimpanan berbasis kolom (columnar storage)**. Hal ini memungkinkan sistem hanya membaca kolom yang diperlukan saat proses analisis, sehingga mempercepat proses query dan mengurangi penggunaan I/O disk.

Kedua, **Parquet mendukung kompresi data secara otomatis**. Hal ini membuat ukuran file menjadi lebih kecil dibandingkan format CSV. Berdasarkan hasil praktikum, ukuran dataset mentah (`ecommerce_raw.csv`) adalah sekitar **6.2 MB**, sedangkan dataset hasil pembersihan dalam format Parquet hanya sekitar **2.3 MB**. Ini menunjukkan bahwa Parquet mampu menghemat ruang penyimpanan secara signifikan.

Ketiga, format Parquet sangat cocok digunakan dalam ekosistem Big Data seperti **Apache Spark, Hadoop, dan Data Lake**, karena mendukung pemrosesan paralel dan optimasi query yang lebih baik.

Dengan kelebihan tersebut, penggunaan Parquet dapat meningkatkan performa analisis data sekaligus menghemat kapasitas penyimpanan.

```
● (venv) rahmah_230104040059@mgfrwr:~/bigdata-project$ du -sh data/clean/parquet/
  2.3M    data/clean/parquet/
● (venv) rahmah_230104040059@mgfrwr:~/bigdata-project$ du -sh data/raw/ecommerce_raw.csv
  6.2M    data/raw/ecommerce_raw.csv
```

**3. Penjelasan Partition Pruning**

Partition pruning merupakan teknik optimasi dalam sistem Big Data yang digunakan untuk mempercepat proses pembacaan data dengan hanya mengakses partisi data yang relevan dengan query yang dijalankan.

Pada praktikum ini, data hasil transformasi disimpan dalam struktur folder **partitioned_by_category**, yaitu:

`data/clean/partitioned_by_category/`

Dalam struktur ini, data dibagi berdasarkan nilai kategori produk. Dengan cara ini, ketika analisis hanya membutuhkan data dari kategori tertentu, sistem tidak perlu membaca seluruh dataset, melainkan hanya membaca folder partisi yang relevan.

Sebagai contoh, jika analisis hanya memerlukan data dari kategori **Electronics**, maka Spark hanya akan membaca partisi data kategori tersebut tanpa harus memproses data kategori lainnya seperti **Computing** atau **Accessories**.

Teknik partition pruning ini sangat penting dalam sistem Big Data karena dapat **mengurangi waktu query, meningkatkan efisiensi pemrosesan, dan menghemat sumber daya komputasi**.

**4. Hasil Analisis Top 5 Produk**

Berdasarkan hasil agregasi data yang dilakukan oleh pipeline, diperoleh daftar **5 produk dengan total penjualan tertinggi** sebagai berikut:

| **Produk** | **Total Quantity** |
|---|---|
| Tablet | 40.898 |
| Laptop | 40.654 |
| Monitor | 40.629 |
| Headphones | 40.506 |
| Phone | 40.314 |

Dari hasil tersebut dapat diketahui bahwa **Tablet merupakan produk dengan jumlah penjualan tertinggi**, yaitu sebanyak **40.898 unit**. Selisih penjualan antar produk dalam daftar ini relatif kecil, yang menunjukkan bahwa permintaan terhadap perangkat elektronik cukup merata di antara beberapa jenis produk populer seperti laptop, monitor, dan smartphone.

Hasil ini menunjukkan bahwa kategori perangkat komputasi dan elektronik memiliki tingkat permintaan yang cukup tinggi dalam dataset transaksi yang dianalisis.

**5. Insight Bisnis dari Hasil Praktikum**

Berdasarkan hasil analisis data yang dilakukan dalam pipeline ini, terdapat beberapa insight bisnis sederhana yang dapat diperoleh.

Pertama, produk seperti **Tablet, Laptop, dan Monitor** memiliki tingkat penjualan yang sangat tinggi. Hal ini menunjukkan bahwa perangkat komputasi masih menjadi kebutuhan utama bagi konsumen, baik untuk keperluan kerja, pendidikan, maupun hiburan.

Kedua, analisis **Category Revenue** menunjukkan bahwa kategori **Electronics dan Computing** menghasilkan pendapatan yang sangat besar dibandingkan kategori lainnya. Ini menandakan bahwa produk teknologi memiliki kontribusi yang signifikan terhadap total pendapatan dalam sistem e-commerce.

Ketiga, penggunaan pipeline batch seperti yang dilakukan pada praktikum ini memungkinkan perusahaan untuk secara rutin menganalisis data transaksi dalam jumlah besar. Dengan demikian, perusahaan dapat memonitor tren penjualan, mengetahui produk yang paling diminati pelanggan, serta mengambil keputusan bisnis yang lebih tepat berdasarkan data yang tersedia.

Melalui pendekatan ini, perusahaan dapat meningkatkan strategi pemasaran, mengelola stok produk secara lebih efektif, dan meningkatkan performa bisnis secara keseluruhan.